PPE VISION · PANDUAN BELAJAR DASHBOARD

Memahami Dashboard, Eksperimen, dan Grafik

Penjelasan menyeluruh tentang isi layar, sumber data, arti setiap metrik dan grafik, keputusan membuat eksperimen read-only, alur kode, keamanan production, serta jawaban yang dapat dipakai saat presentasi.

5	9	3
metrik utama	artefak evaluasi	kelas PPE

Model final: PPE YOLO26s Dataset 4 Final

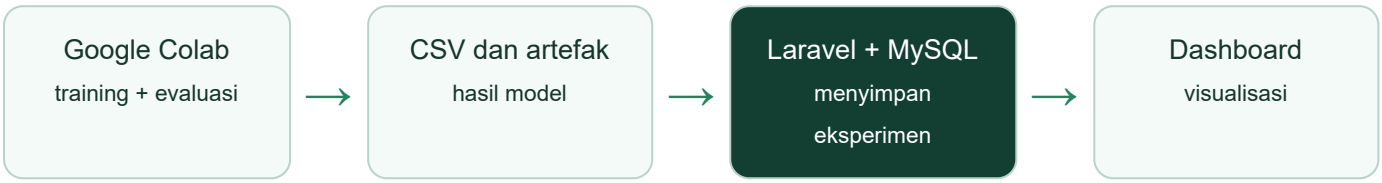
Basis audit: source code dan database lokal yang sama dengan deployment final

Tanggal: 15 Oktober 2026

CARA MENGGUNAKAN LAPORAN

Urutan belajar yang paling mudah

Jangan menghafal grafik satu per satu. Mulailah dari aliran data: hasil training masuk ke database, dashboard membaca database, lalu grafik mengubah angka menjadi bentuk visual.



Jika waktu belajar 30 menit

1. Bab 2: anatomi dashboard.
2. Bab 4–7: metrik dan grafik.
3. Bab 9–11: alur eksperimen final.
4. Bab 18: pertanyaan presentasi.

Kalimat inti

Dashboard **tidak menghitung ulang model**. Dashboard adalah lapisan pelacakan eksperimen dan komunikasi hasil: angka sudah dihitung oleh evaluasi YOLO, kemudian disimpan dan ditampilkan secara konsisten.

DAFTAR ISI

Isi laporan

1. Tujuan dashboard
2. Anatomi halaman utama
3. Dari URL sampai data tampil
4. Lima kartu metrik
5. IoU, AP, dan mAP
6. Training curve
7. Performa per kelas
8. Eksperimen terbaru
9. Halaman daftar eksperimen
10. Mengapa fitur create dihapus
11. Siklus hidup model final
12. Halaman detail
13. Sembilan artefak evaluasi
14. Hubungan dengan AI Summary
15. Status fitur final
16. Database dan source of truth
17. Keamanan dan batasan
18. Pertanyaan presentasi
19. Skenario demo
20. Peta file dan checklist

BAB 1

Apa tujuan dashboard ini?

Dashboard PPE Vision menjawab empat pertanyaan manajemen model:

1. Seberapa baik model?

Dijawab oleh precision, recall, F1, mAP50, dan mAP50-95 pada test independen.

2. Apakah training stabil?

Dijawab oleh training curve per epoch dan artefak losses di detail eksperimen.

3. Kelas mana yang lemah?

Dijawab oleh mAP50-95 per kelas, confusion matrix, serta kurva PR/F1.

4. Bagaimana hasil direproduksi?

Dijawab oleh catatan model, dataset, epoch, batch, image size, optimizer, device, artefak, dan riwayat eksperimen.

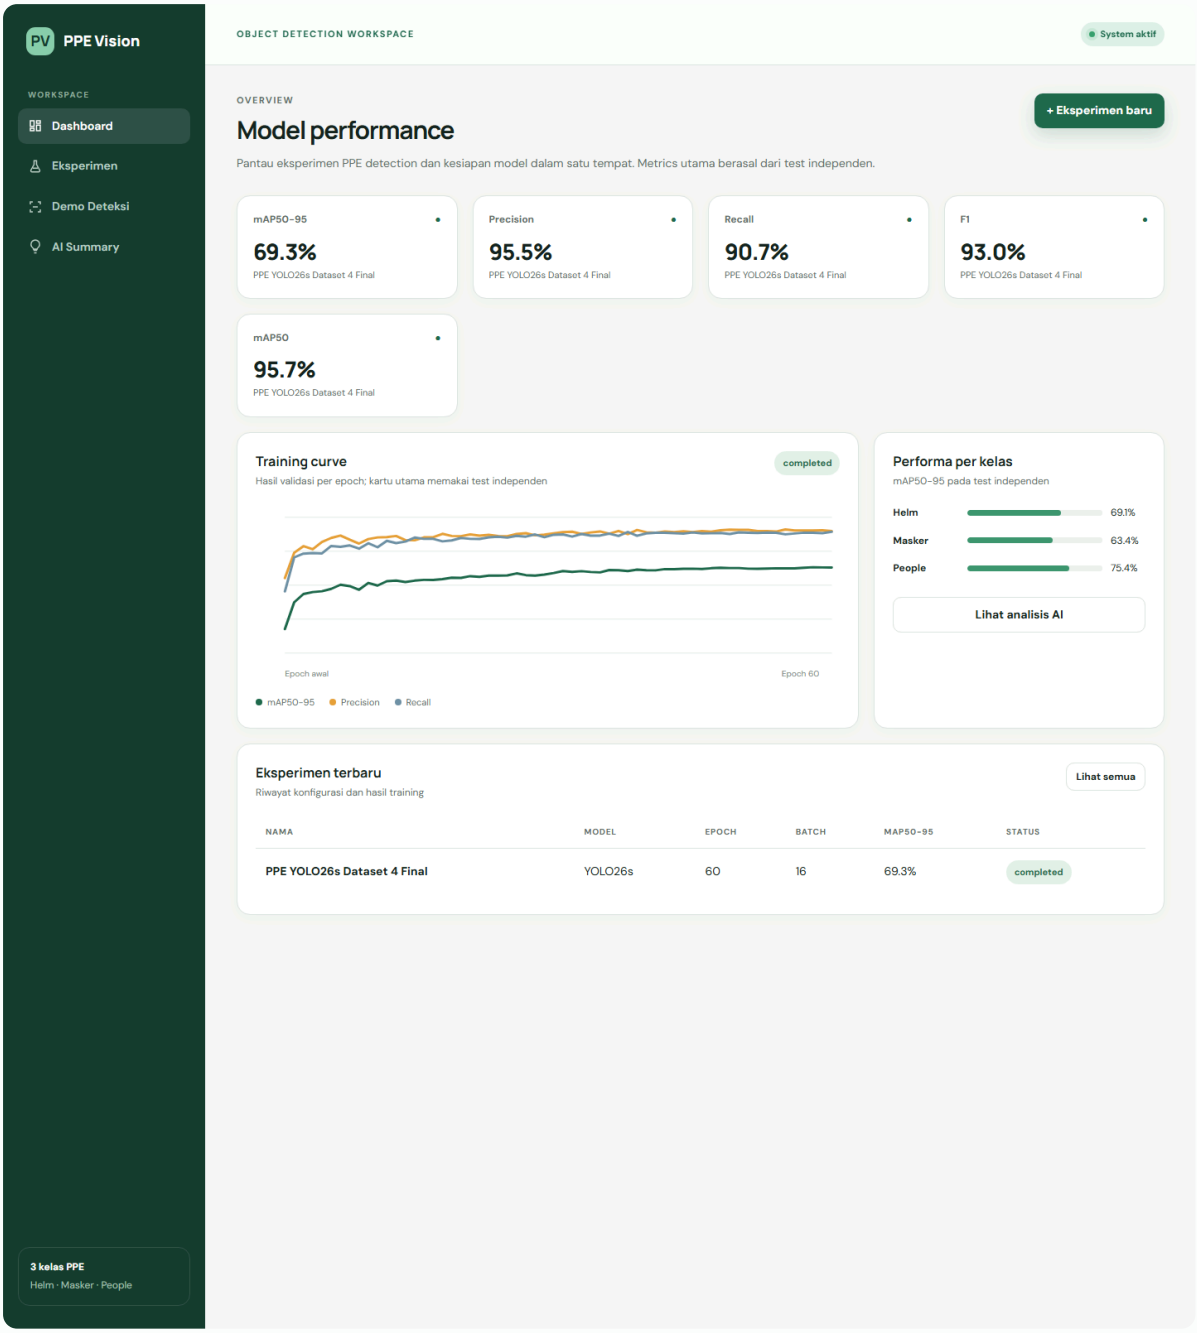
> **Mengapa bukan hanya menampilkan demo deteksi?** Satu video yang terlihat bagus dapat menyesatkan. Dashboard menampilkan evaluasi terukur pada banyak gambar dan menyimpan konteks training sehingga keputusan tidak bergantung pada satu contoh.

Tiga peran utama

Peran	Yang diperoleh	Contoh keputusan
Developer/ML engineer	Riwayat parameter, kurva, kelas lemah	Perbaiki dataset Masker dan uji threshold.
Recruiter/assessor	Bukti model dievaluasi, bukan sekadar demo	Memastikan precision, recall, mAP tersedia.
Pengguna operasional	Ringkasan kemampuan dan risiko	Tidak langsung memakai model tanpa uji lapangan.

BAB 2

Anatomi halaman Dashboard



Screenshot dokumentasi sebelum penyederhanaan. Pada versi final, tombol Eksperimen Baru sudah dihapus; kartu, grafik, dan detail hasil tetap sama.

1. **Sidebar.** Dashboard untuk ringkasan; Eksperimen untuk riwayat; Demo Deteksi untuk mencoba model; AI Summary untuk penjelasan otomatis.

2. **System aktif.** Saat ini merupakan indikator UI statis bahwa portal berhasil dirender—bukan health check real-time untuk MySQL, Streamlit, FastAPI, dan Ollama secara terpisah.

3. **Eksperimen read-only.** Versi final hanya menampilkan konfigurasi dan hasil yang sudah dievaluasi; tidak ada tombol yang memberi kesan training dimulai dari Laravel.

4. **Lima kartu metrik.** Snapshot hasil final pada split test independen.

5. **Training curve.** Tren precision, recall, dan mAP50-95 dari validation pada setiap epoch.

6. **Performa per kelas.** Membandingkan Helm, Masker, dan People menggunakan mAP50-95 test.

7. **Eksperimen terbaru.** Lima run terbaru; tombol Lihat semua membuka daftar dengan pagination.

> **Catatan presentasi:** jangan mengatakan lampu “System aktif” membuktikan seluruh service sehat. Kalimat yang akurat: “Portal Laravel aktif; kesehatan inference diverifikasi ketika halaman demo memanggil layanan deteksi.”

BAB 3

Dari URL sampai angka tampil



Controller memilih data

```
$latestRun = TrainingRun::latest('finished_at')->first();

return view('dashboard', [
    'latestRun' => $latestRun,
    'runs' => TrainingRun::latest()->take(5)->get(),
    'experimentCount' => TrainingRun::count(),
    'detectionCount' => Detection::where('status', 'completed')->count(),
]);
```

Variabel	Fungsi	Dipakai saat ini?
`latestRun`	Run dengan `finished_at` paling baru untuk kartu dan grafik.	Ya.
`runs`	Lima record terbaru untuk tabel bawah.	Ya.
`experimentCount`	Total eksperimen.	Sudah disiapkan controller, belum divisualkan.
`detectionCount`	Total inference yang selesai.	Sudah disiapkan controller, belum divisualkan.

Mengapa pola MVC baik?

Route hanya menentukan alamat, controller mengambil data, model memetakan tabel database, dan Blade mengurus tampilan. Pemisahan ini membuat angka dapat dites tanpa browser dan desain dapat diubah tanpa mengubah logika database.

BAB 4

Memahami lima kartu metrik utama

Test

Precision

95,5%

Dari seluruh deteksi positif yang dibuat model, proporsi yang benar sangat tinggi. Fokusnya adalah mengendalikan *false positive*.

Test

Recall

90,7%

Dari seluruh objek target yang benar-benar ada, model menemukan sebagian besar. Kekurangannya berkaitan dengan *false negative*.

Test

F1

93,0%

Rata-rata harmonik precision dan recall; tinggi hanya bila keduanya sama-sama kuat.

IoU 0,50

mAP50

95,7%

Rata-rata AP tiga kelas ketika prediksi dianggap cocok pada IoU minimal 0,50.

IoU 0,50–0,95

mAP50-95

69,3%

Rata-rata AP pada sepuluh ambang IoU. Lebih ketat dan menjadi indikator utama kualitas lokalisasi.

Sumber

212

Jumlah gambar test independen. Data test tidak digunakan untuk memperbarui bobot saat training.

```
Precision = TP / (TP + FP)
Recall    = TP / (TP + FN)
F1        = 2 × Precision × Recall / (Precision + Recall)
```

Contoh konseptual

Jika model membuat 100 prediksi dan 95 benar, precision kira-kira 95%. Jika terdapat 100 objek sebenarnya dan 91 ditemukan, recall kira-kira 91%. Angka dashboard dihitung dengan prosedur evaluasi Ultralytics lintas kelas dan confidence, sehingga contoh ini hanya untuk membangun intuisi—bukan rekonstruksi hitungan mentah.

> **Bukan accuracy.** Object detection harus menilai kelas sekaligus posisi kotak. Karena itu precision, recall, AP, dan mAP lebih informatif daripada accuracy klasifikasi biasa.

BAB 5

Mengapa mAP50 tinggi tetapi mAP50-95 lebih rendah?

IoU mengukur tumpang tindih kotak

```
IoU = luas irisan(prediksi, ground truth) / luas gabungan(prediksi, ground truth)
```

mAP50 = 95,7%

Pada syarat IoU 0,50, banyak kotak sudah cukup mengenai objek. Ini bagus untuk menjawab “apakah objek ditemukan?”.

mAP50-95 = 69,3%

Syarat dinaikkan bertahap sampai 0,95. Kotak harus semakin presisi mengikuti batas objek, sehingga nilainya wajar lebih rendah.

Selisih sekitar **26,4 poin persentase** bukan bug. Artinya kemampuan menemukan objek pada batas longgar sangat kuat, sedangkan presisi lokalisasi pada ambang sangat ketat masih memiliki ruang perbaikan. Masker kecil, wajah miring, dan occlusion dapat membuat batas kotak lebih sulit tepat.

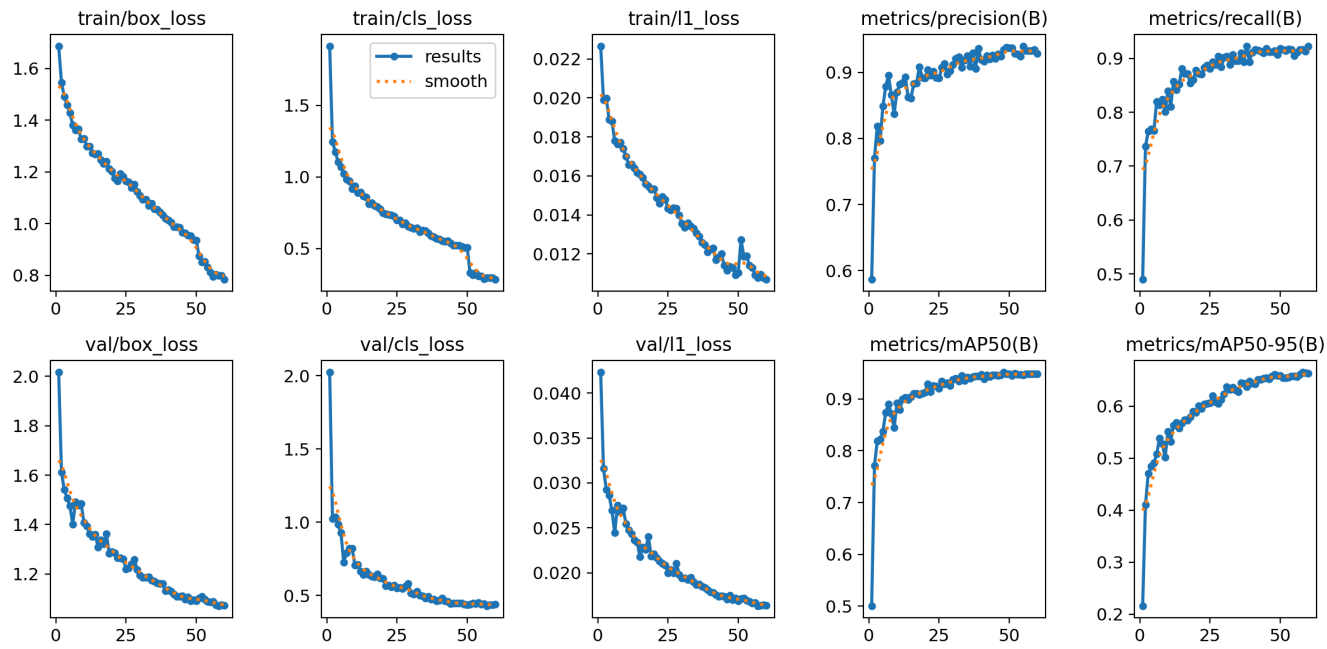
Dari AP menuju mAP

1. Untuk satu kelas, prediksi diurutkan berdasarkan confidence.
2. Precision dan recall dihitung pada berbagai threshold.
3. Luas di bawah kurva Precision–Recall menjadi AP.
4. AP kelas Helm, Masker, dan People dirata-ratakan menjadi mAP.
5. mAP50-95 juga merata-ratakan hasil pada IoU 0,50; 0,55; …; 0,95.

> **Jawaban wawancara:** “Saya memilih mAP50-95 sebagai metrik utama karena lebih ketat dan tidak hanya memberi nilai tinggi ketika kotak sekadar menyentuh objek.”

BAB 6

Membaca Training curve



Artefak asli 60 epoch. Dashboard mengambil tiga seri validation: precision, recall, dan mAP50-95.

Apa yang digambar dashboard?

Warna	Data	Makna
Hijau	mAP50-95 validation	Kualitas gabungan klasifikasi dan lokalisasi ketat.
Oranye	Precision validation	Seberapa bersih prediksi positif pada setiap epoch.
Biru	Recall validation	Seberapa lengkap objek validation ditemukan.

Cara SVG dibuat

Setiap baris `training_history` menjadi satu titik. Posisi horizontal mengikuti urutan epoch, sedangkan posisi vertikal dihitung dari nilai 0–1. Titik disambungkan sebagai `polyline`. Grafik ini ringan karena tidak memerlukan library chart eksternal.

```
x = 35 + index × (655 / (jumlah_epoch - 1))
y = 190 - nilai_metrik × 170
```

Interpretasi model final

- Peningkatan paling besar terjadi pada epoch awal: model cepat mempelajari pola dasar.
- Kurva kemudian melandai: training mendekati konvergensi, bukan berhenti bekerja.
- Fluktuasi kecil antar-epoch normal akibat batch dan variasi data.

- Best epoch adalah 58; checkpoint `best.pt` dipilih berdasarkan performa validation terbaik, bukan sekadar epoch terakhir.
- Loss train dan validation sama-sama turun pada artefak lengkap; tidak terlihat divergensi ekstrem yang langsung menunjukkan overfitting berat.

> **Mengapa grafik memakai validation, tetapi kartu memakai test?** Validation dipantau selama pengembangan dan pemilihan checkpoint. Test baru dipakai sebagai evaluasi akhir yang lebih independen. Mencampur keduanya tanpa label akan menyesatkan, sehingga dashboard menuliskan sumber masing-masing.

> **Batas grafik dashboard:** tidak ada label angka sumbu-Y atau tooltip. Grafik cocok untuk melihat tren, bukan membaca nilai epoch tertentu secara presisi. Nilai detail tersedia pada CSV.

BAB 7

Performa per kelas

Kelas aplikasi	Kelas sumber	Precision	Recall	F1	mAP50	mAP50-95
Helm	Helmet	96,3%	89,5%	92,8%	96,2%	69,1%
Masker	Mask	92,9%	87,5%	90,1%	93,1%	63,4%
People	Person	97,2%	95,1%	96,2%	97,7%	75,4%

People paling stabil

Nilai tertinggi pada semua metrik utama. Tubuh manusia biasanya lebih besar daripada masker sehingga pola visual dan kotaknya lebih mudah dipelajari.

Masker perlu perhatian

mAP50-95 63,4% adalah yang terendah. Masker relatif kecil, bentuk/warna beragam, dapat tertutup, dan anotasi “semuka” atau tidak konsisten dapat mengganggu lokalisasi.

Mengapa bar memakai mAP50-95?

Agar perbandingan kelas menggunakan ukuran yang ketat dan konsisten. Panjang bar hanyalah representasi `nilai × 100%`; ia tidak mengubah data.

> **Yang tidak boleh disimpulkan:** nilai agregat tiga kelas tidak menjamin ketiganya akan selalu muncul bersamaan dalam setiap frame. Jika sebuah frame tidak memiliki Helm atau Masker yang terlihat, model tidak harus memunculkannya. Kemampuan simultan harus diuji pada gambar/video yang benar-benar memuat ketiga objek dan anotasinya lengkap.

BAB 8

Bagian “Eksperimen terbaru”

Tabel bawah adalah ringkasan maksimal lima record terbaru berdasarkan waktu pembuatan. Kolomnya dipilih untuk menjawab “run apa, konfigurasi singkat apa, hasil utama berapa, dan statusnya apa?”.

Kolom	Alasan ditampilkan
Nama	Identitas manusiawi, misalnya baseline atau dataset-v4-final.
Model	Membedakan arsitektur/ukuran checkpoint.
Epoch	Jumlah siklus training.
Batch	Jumlah gambar per update; relevan terhadap memori dan dinamika optimisasi.
mAP50-95	Metrik pembanding utama yang ketat.
Status	`draft` berarti baru dicatat; `completed` berarti metrik telah tersedia.

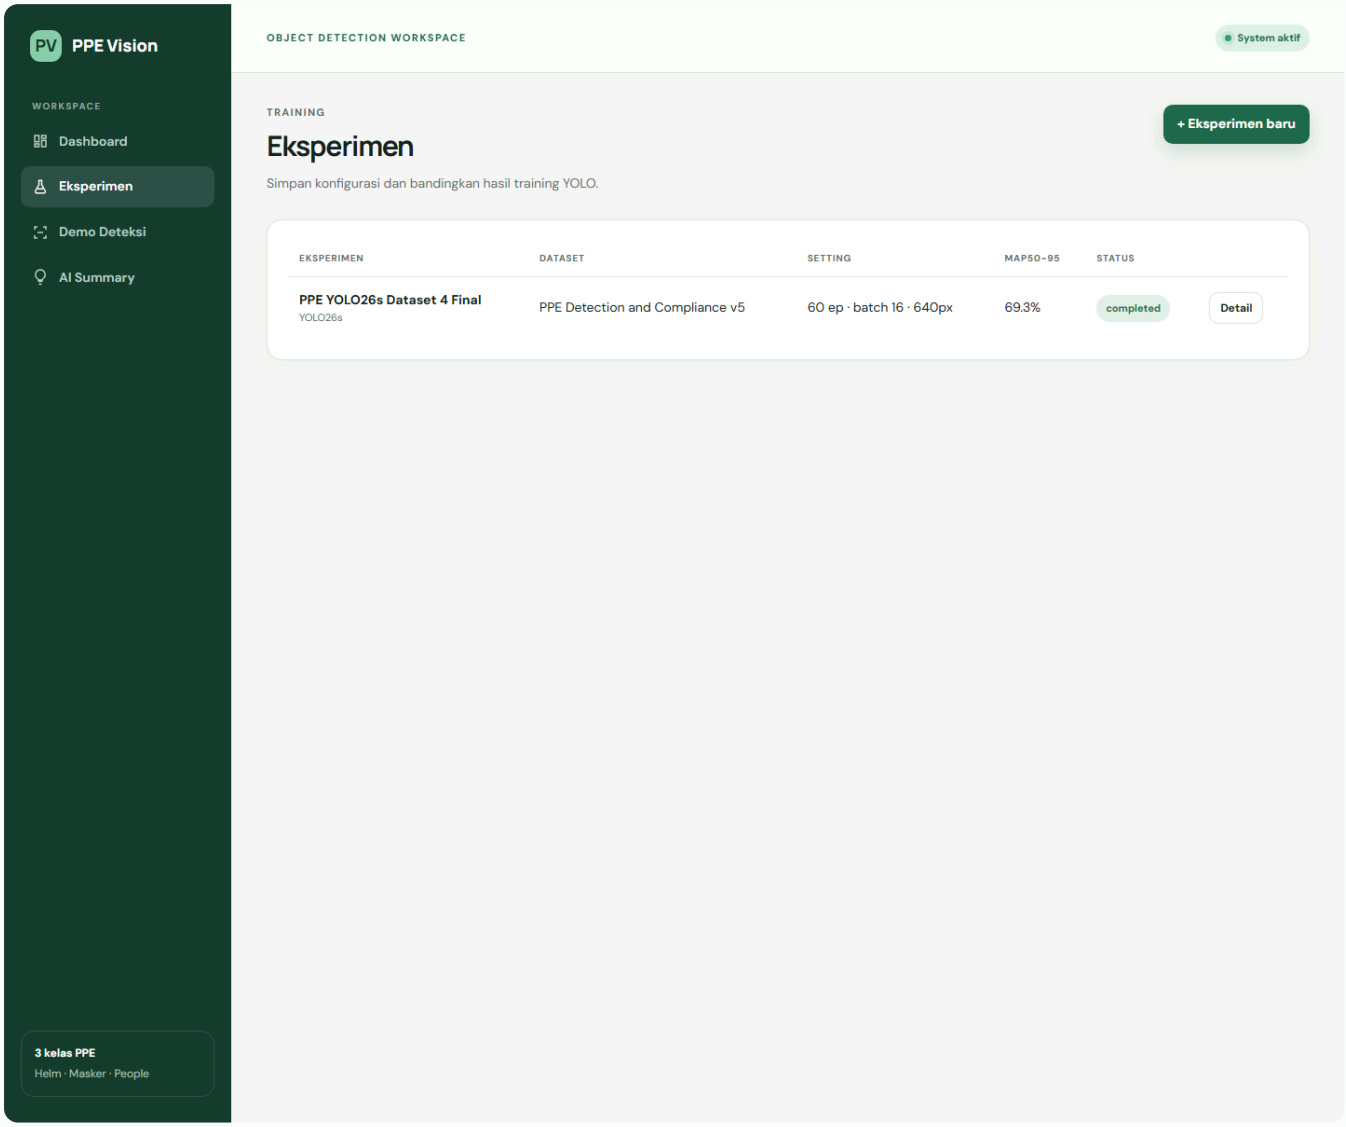
Mengapa hanya lima?

Dashboard harus ringkas. Seluruh riwayat tersedia melalui “Lihat semua”, yang menggunakan pagination 10 record per halaman agar tetap ringan ketika eksperimen bertambah.

> **Prinsip eksperimen:** jangan menimpa hasil lama ketika mencoba dataset atau hyperparameter baru. Buat record baru supaya perbandingan tetap dapat dilacak dan alasan pemilihan model final dapat dibuktikan.

BAB 9

Halaman daftar Eksperimen



Daftar menyatukan identitas eksperimen, dataset, setting, mAP50-95, status, dan tautan detail.

Bedanya dengan dashboard

Dashboard	Daftar eksperimen
Menonjolkan model terbaru dan gambaran cepat.	Menjadi katalog seluruh run.
Maksimal lima run terbaru.	Sepuluh run per halaman dengan pagination.
Memuat kurva dan kelas.	Memudahkan pencarian run dan pembukaan detail.

Tombol **Detail** membuka record yang dipilih menggunakan Laravel route model binding: ID pada URL otomatis diterjemahkan menjadi objek `TrainingRun`. Jika ID tidak ada, Laravel memberi 404.

BAB 10

Mengapa tombol “Eksperimen Baru” dihapus?

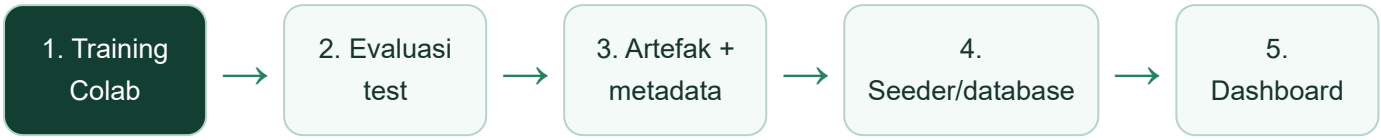
Tombol lama hanya membuat record metadata. Ia tidak menjalankan Python, GPU, atau training YOLO sehingga berpotensi membuat assessor salah memahami kemampuan aplikasi.

Pertimbangan	Keputusan final
Syarat assessment	Tidak meminta CRUD atau tombol membuat eksperimen.
Bukti setting training	Tetap tersedia pada daftar dan detail eksperimen.
Bukti hasil/matriks	Tetap tersedia sebagai metrik, grafik, dan artefak evaluasi.
Training sebenarnya	Tetap dilakukan di Google Colab menggunakan Python/GPU.
Kejelasan UI	Halaman menjadi read-only dan fokus pada model final.

Kesimpulan: menghapus tombol tidak mengurangi pemenuhan assessment. Yang wajib dipertahankan adalah konfigurasi, metrik, matriks/artefak, demo model, dan AI Summary.

BAB 11

Siklus hidup model final



1. **Jalankan training.** Colab menghasilkan `best.pt`, `results.csv`, dan grafik.
2. **Evaluasi test.** Gunakan split independen untuk nilai final.
3. **Validasi artefak.** Cocokkan metadata checkpoint, metrik, dan gambar evaluasi.
4. **Sinkronisasi.** Seeder menyimpan konfigurasi dan hasil final ke database.
5. **Tampilkan.** Dashboard membaca data yang sama secara read-only.

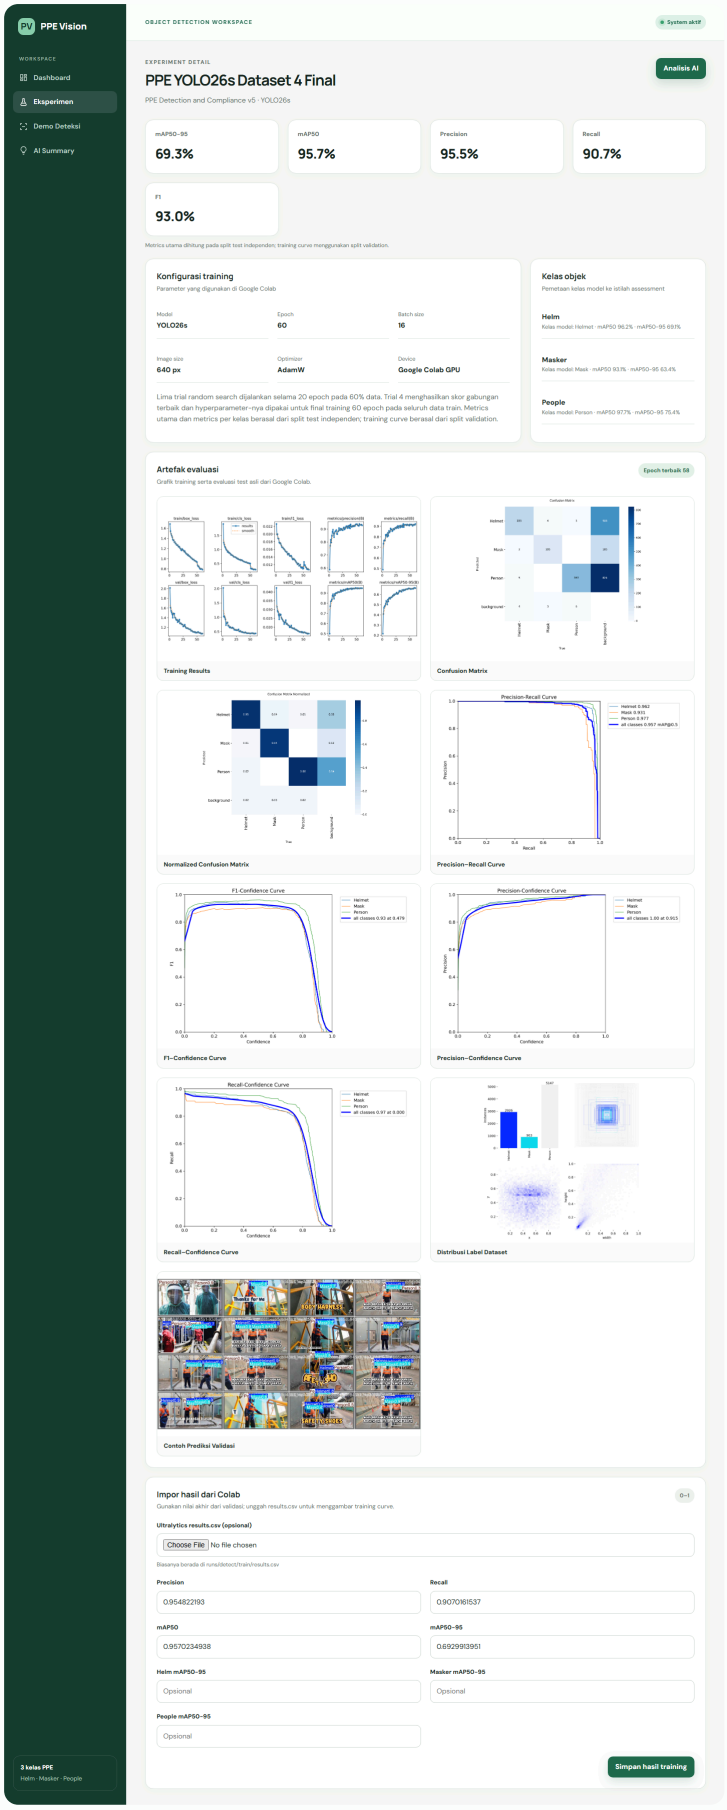
Catatan implementasi saat ini

Form impor membaca `results.csv` untuk epoch, precision, recall, dan mAP50-95. Path sembilan artefak model final ditanam melalui seeder. Belum ada UI umum untuk mengunggah semua gambar artefak satu per satu. Ini bukan error, tetapi batas desain versi sekarang.

> **Run final khusus:** data model final disinkronkan oleh `DatabaseSeeder` dengan metadata checkpoint, sehingga kartu test, nilai per kelas, path artefak, dan ringkasan tetap konsisten setelah instalasi database.

BAB 12

Halaman detail eksperimen



Halaman detail lokal. Di production, bagian Impor hasil dari Colab disembunyikan karena operasi admin dinonaktifkan.

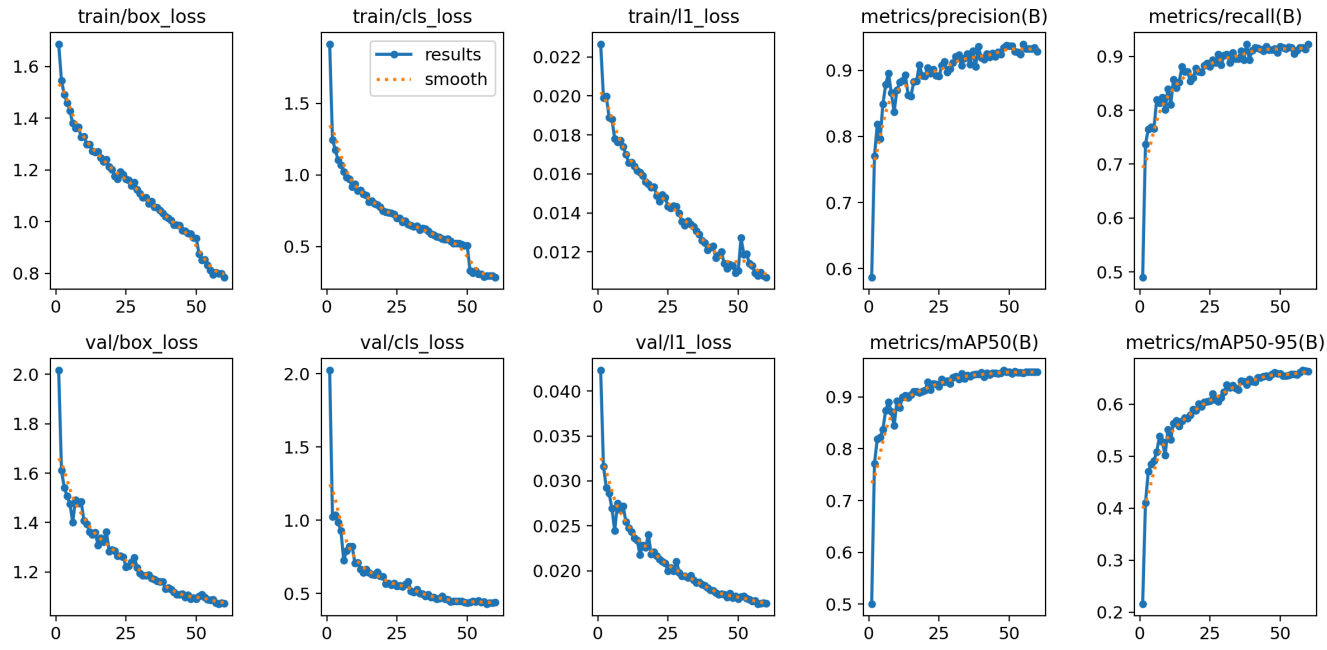
Detail adalah “kartu identitas lengkap” satu run. Bagian atas mengulang lima metrik, lalu menampilkan konfigurasi training, pemetaan kelas, artefak evaluasi, dan—khusus mode admin lokal—form impor.

Bagian	Pertanyaan yang dijawab
Kartu metrik	Seberapa baik hasil final run ini?
Konfigurasi training	Bagaimana run ini dibuat?
Kelas objek	Bagaimana label model dipetakan ke istilah assessment?
Artefak evaluasi	Apakah angka didukung grafik dan contoh prediksi?
Impor hasil	Bagaimana data hasil Colab masuk ke database?
Analisis AI	Bagaimana metrik diterjemahkan menjadi insight?

BAB 13

Cara membaca sembilan artefak evaluasi

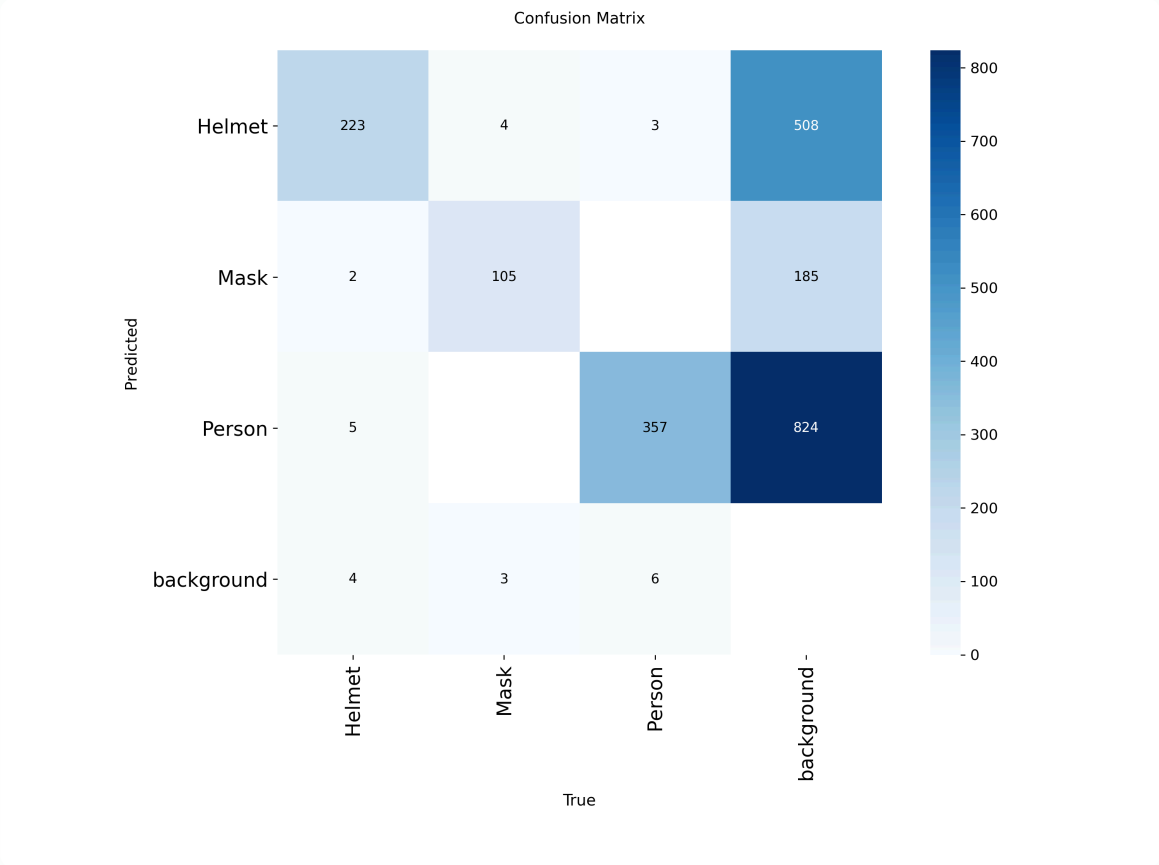
1. Training Results



Loss train/validation turun; precision, recall, mAP meningkat dan melandai.

Fungsi: melihat proses belajar sepanjang epoch. Loss turun berarti kesalahan optimisasi berkurang. Kurva validation yang membaik bersama train memberi indikasi generalisasi, walau keputusan overfitting sebaiknya tetap memakai data numerik dan contoh baru.

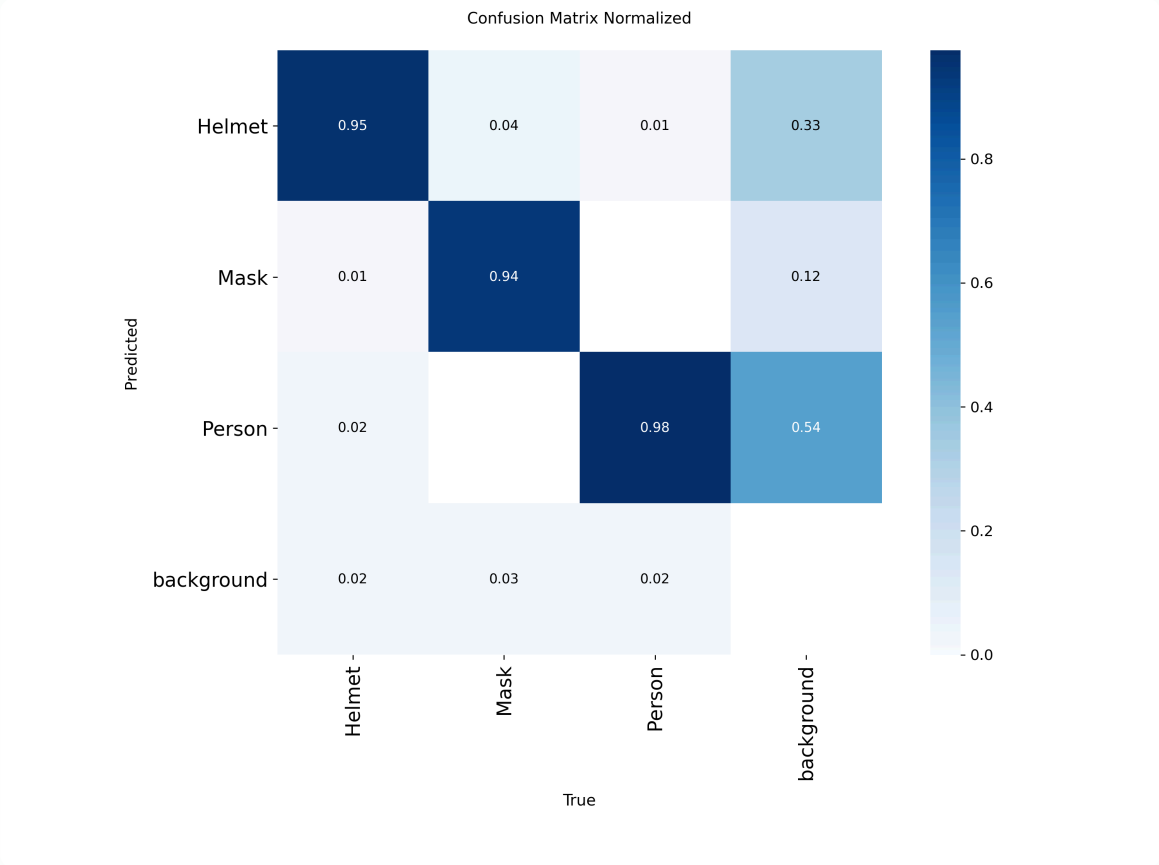
2. Confusion Matrix



Jumlah absolut prediksi vs kelas sebenarnya, termasuk background.

Fungsi: mengetahui jenis kesalahan, bukan hanya skor total. Diagonal berarti prediksi kelas benar; sel di luar diagonal menunjukkan kelas tertukar atau objek/background keliru.

3. Normalized Confusion Matrix

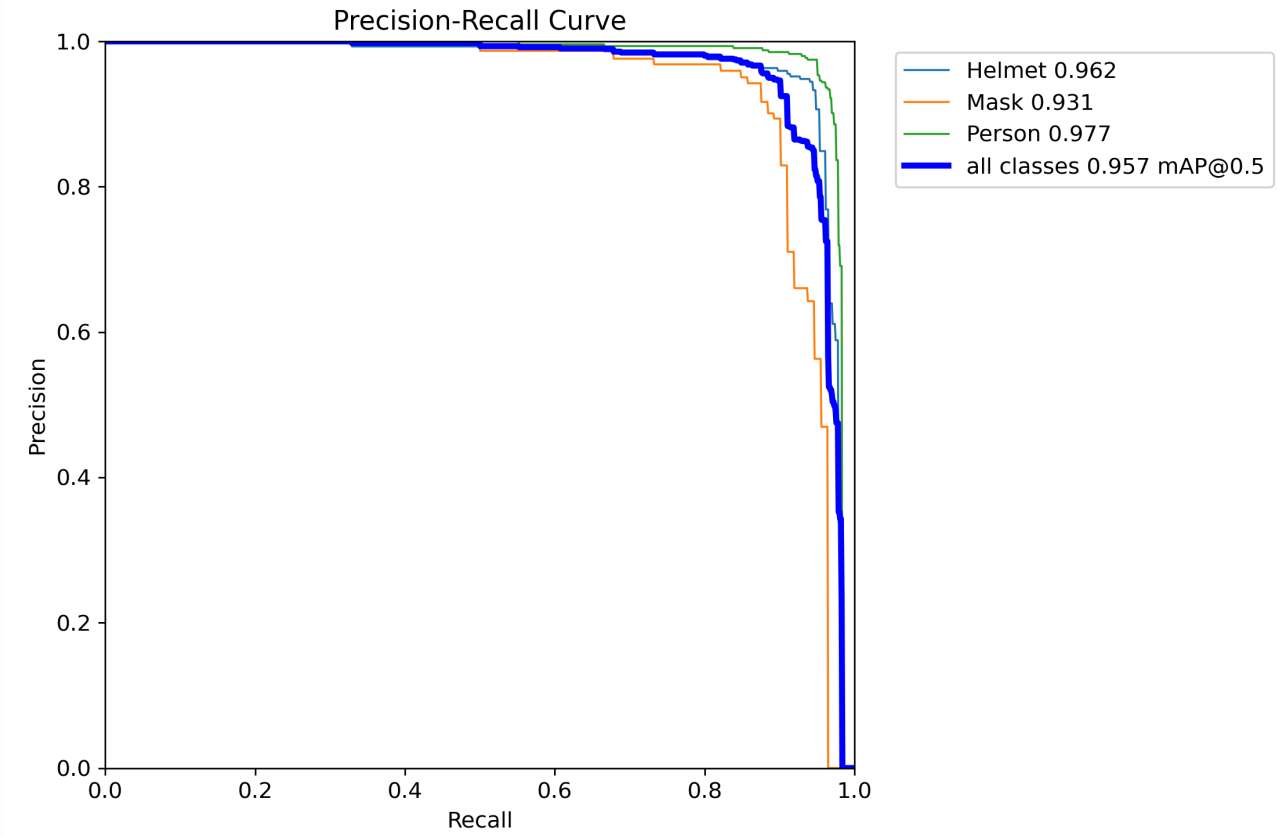


Proporsi yang dinormalisasi memudahkan perbandingan kelas dengan jumlah contoh berbeda.

Mengapa perlu dua matrix? Matrix absolut menunjukkan volume kasus; normalized menunjukkan rasio. Kelas kecil dapat tampak tidak penting pada hitungan mentah tetapi sebenarnya mempunyai rasio kesalahan tinggi.

Kurva threshold dan kualitas lokalisasi

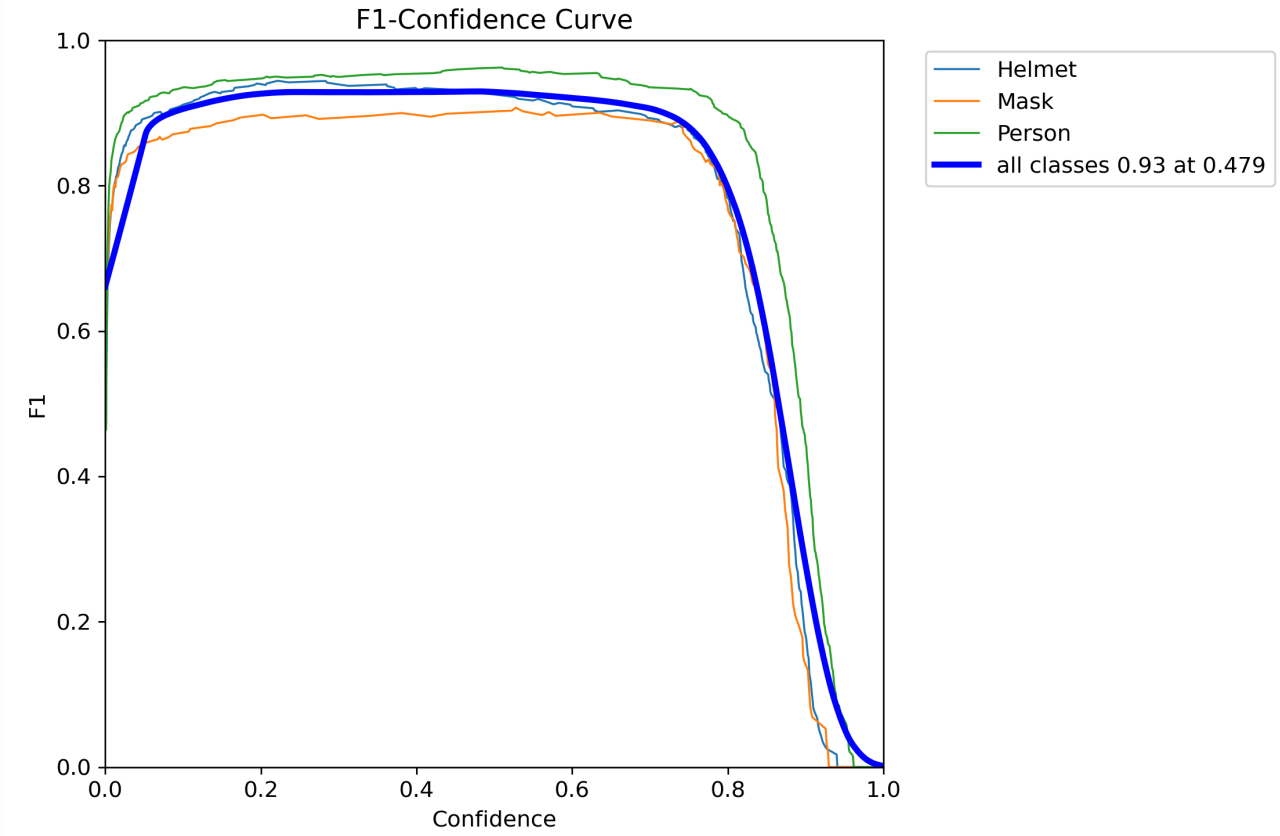
4. Precision–Recall Curve



Kurva mendekati sudut kanan atas menandakan trade-off precision/recall yang baik.

Fungsi: menunjukkan hubungan precision dan recall ketika confidence threshold berubah. Luas kurva berhubungan dengan AP. Garis Mask lebih rendah daripada kelas lain, sesuai kesimpulan bahwa Masker adalah kelas terlemah.

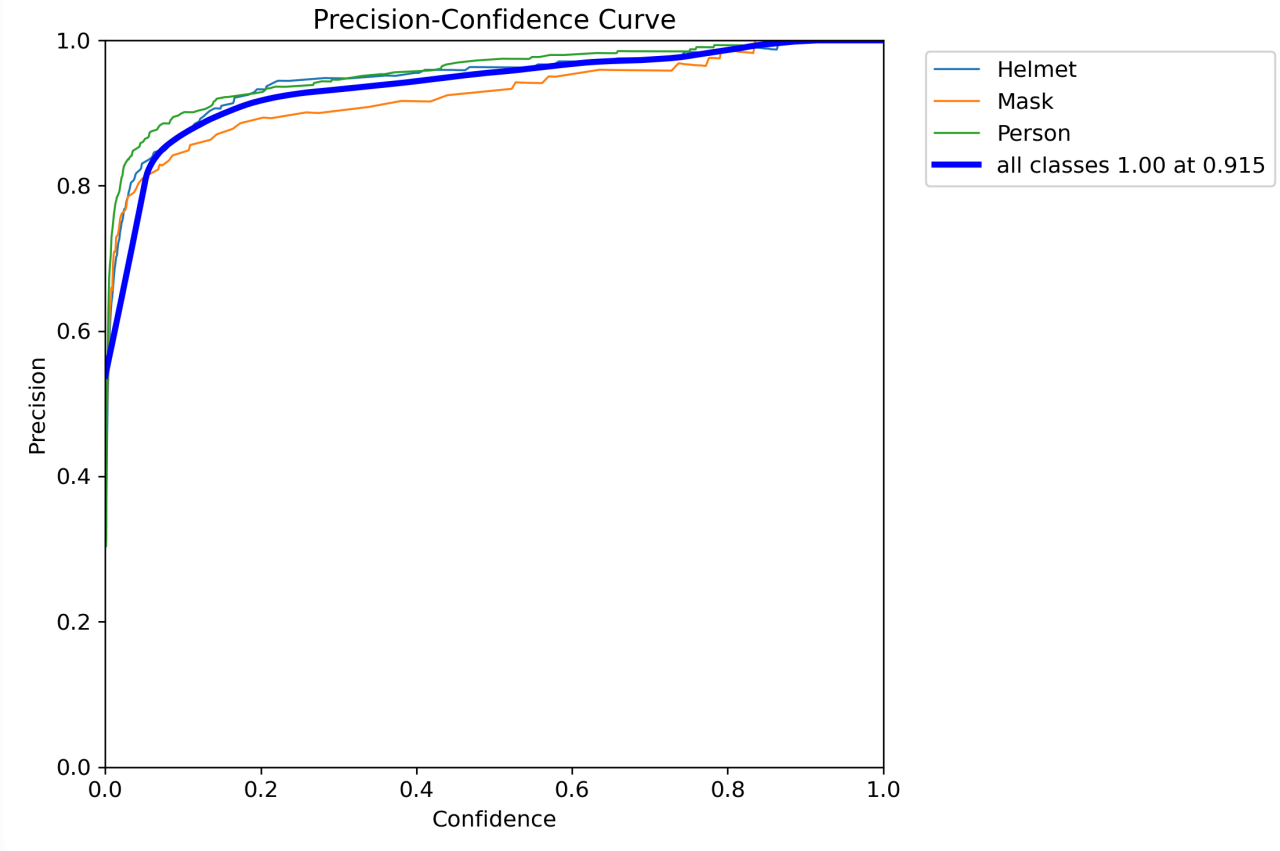
5. F1–Confidence Curve



Digunakan untuk mencari titik keseimbangan precision dan recall.

F1 biasanya naik ketika prediksi sangat lemah disaring, mencapai puncak, lalu turun ketika threshold terlalu tinggi dan banyak objek terlewat. Puncak global pada artefak memberi kandidat threshold, tetapi threshold produksi tetap harus diuji pada video lapangan.

6. Precision–Confidence Curve



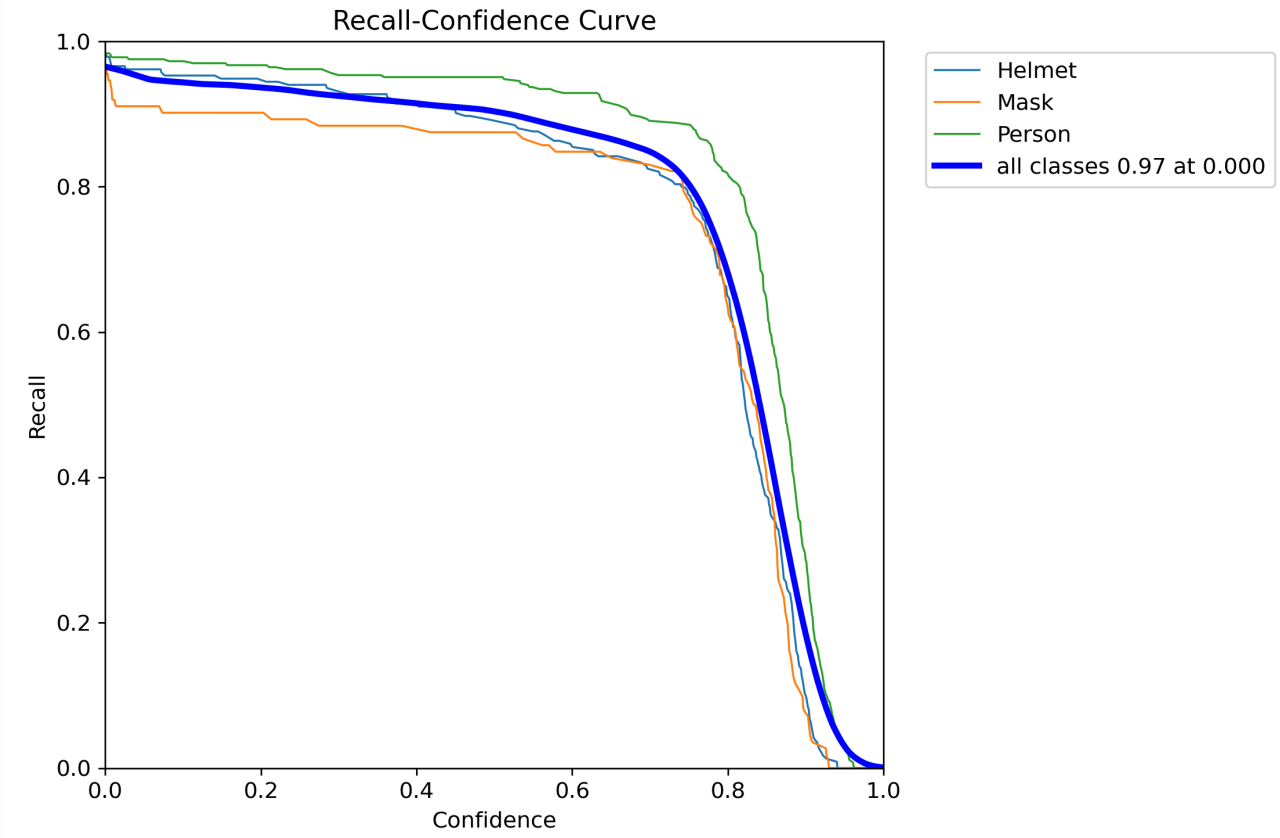
Semakin tinggi threshold, prediksi yang dipertahankan biasanya semakin bersih.

Konsekuensi: menaikkan confidence mengurangi false positive, tetapi tidak gratis—recall biasanya ikut menurun.

BAB 13 · LANJUTAN

Recall, distribusi data, dan pemeriksaan visual

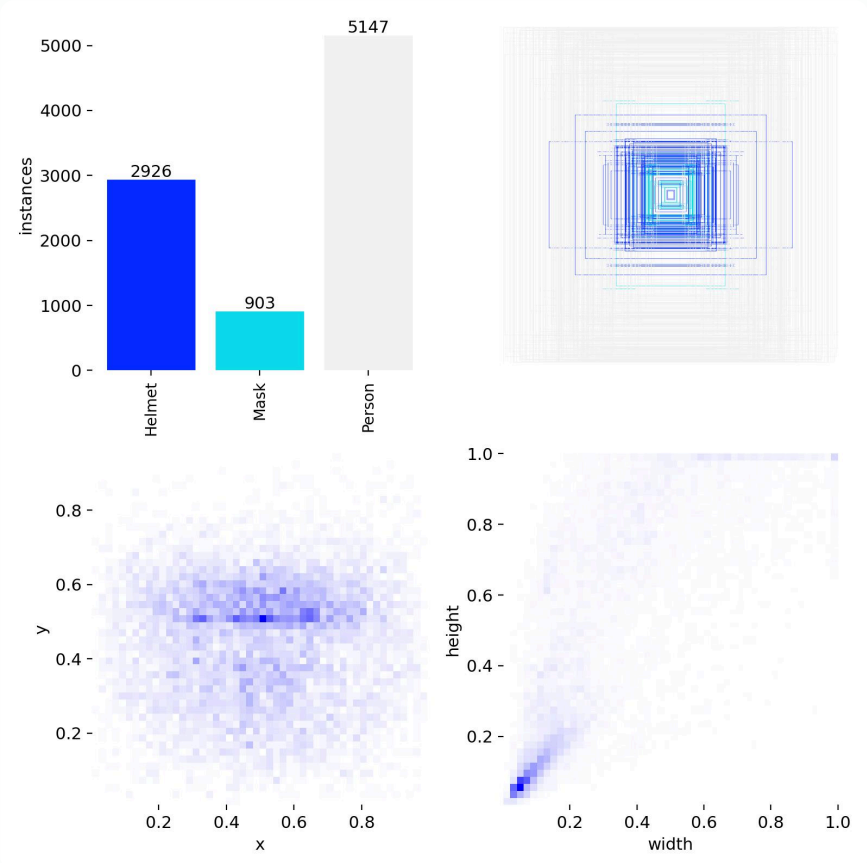
7. Recall–Confidence Curve



Recall cenderung turun ketika threshold dinaikkan karena lebih banyak prediksi dibuang.

Untuk keselamatan, false negative bisa lebih berbahaya daripada false positive. Threshold sebaiknya tidak dipilih hanya untuk membuat tampilan “bersih”; perlu menimbang objek PPE yang terlewat.

8. Distribusi Label Dataset



Jumlah label dan distribusi posisi/ukuran bounding box.

Fungsi: menemukan ketidakseimbangan kelas, dominasi ukuran tertentu, atau posisi objek yang bias. Model dapat lemah pada masker kecil apabila dataset lebih banyak berisi kotak besar atau anotasi wajah yang tidak konsisten.

9. Contoh Prediksi Validation

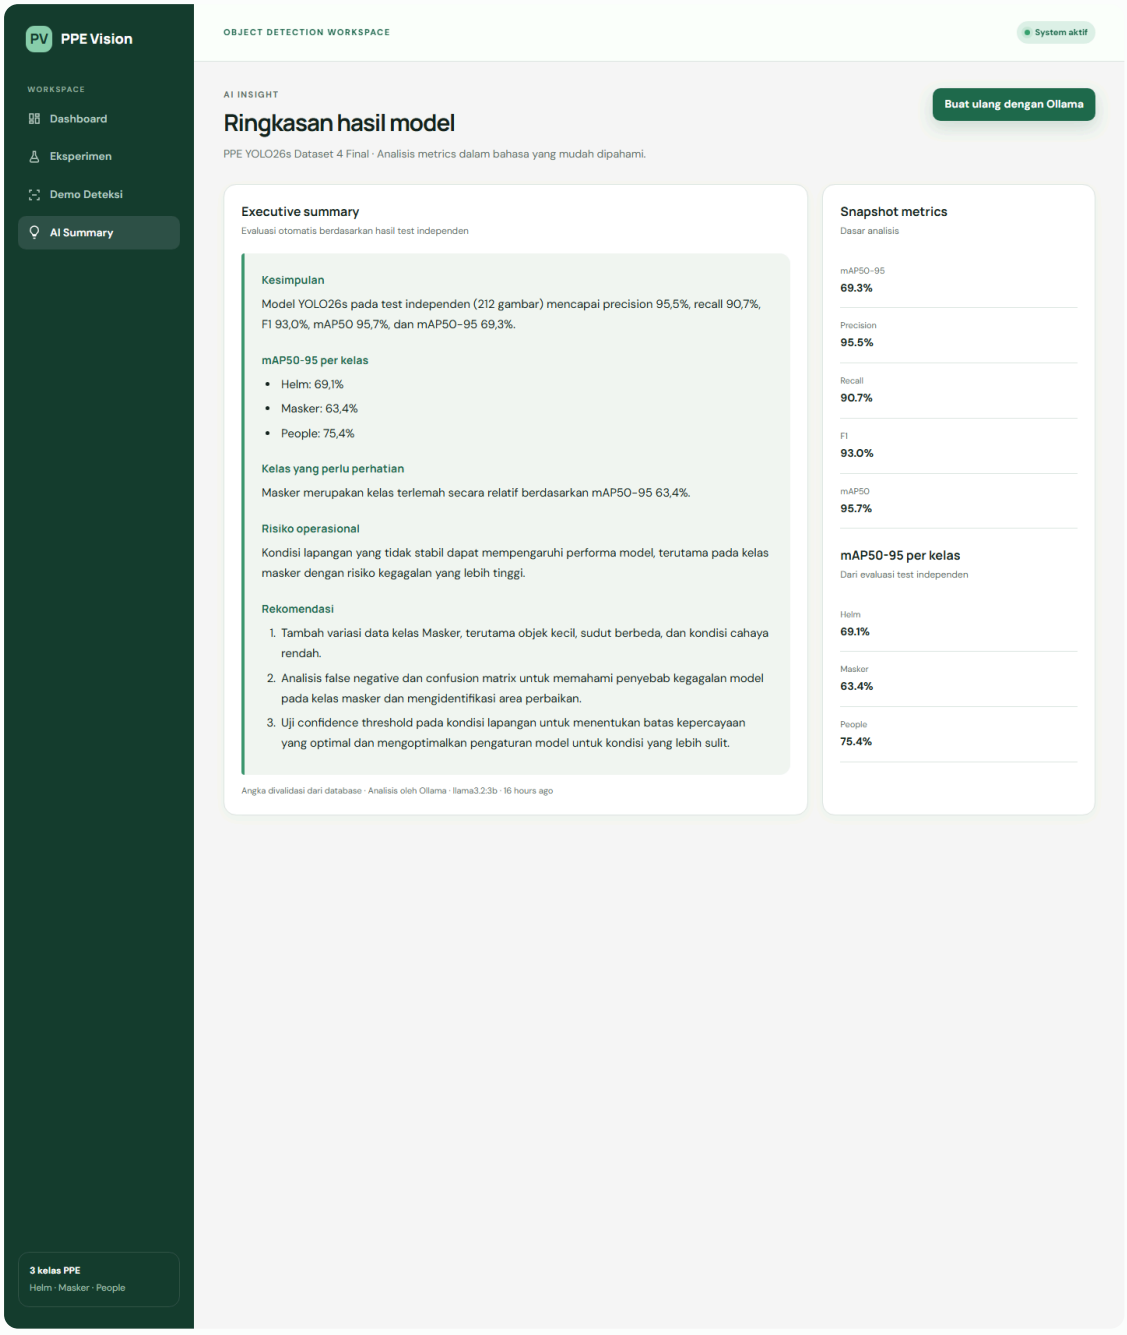


Pemeriksaan kualitatif untuk memastikan kotak dan label masuk akal.

Angka agregat tidak dapat menunjukkan setiap kegagalan. Contoh prediksi membantu menemukan kotak terlalu lebar, label ganda, objek kecil terlewat, atau ground truth yang bermasalah. Namun satu montage juga tidak boleh menggantikan evaluasi seluruh dataset.

BAB 14

Hubungan dashboard dengan AI Summary



Summary menggunakan angka database yang sama dengan dashboard sehingga tidak boleh menghasilkan angka sendiri.

Metrics DB → **MetricSummaryService** → Ollama lokal → Validasi + simpan

Tombol “Lihat analisis AI” membawa pengguna dari visual ke narasi. Ollama hanya diminta memberi risiko operasional dan tiga rekomendasi. Kesimpulan angka dan kelas terlemah dihitung Laravel dari database. Jika respons tidak sesuai schema atau Ollama gagal, sistem memakai ringkasan deterministik berbasis aturan.

Yang dilakukan AI

Mengubah pola metrik menjadi bahasa yang mudah dibaca, risiko, dan tindakan lanjutan.

Yang tidak dilakukan AI

Tidak menghitung ulang mAP, tidak mengevaluasi gambar, dan tidak menjadi sumber kebenaran numerik.

> **Mengapa angka sama?** Dashboard dan summary membaca record `TrainingRun` yang sama. Prompt melarang LLM menulis angka; Laravel menyisipkan angka yang sudah divalidasi.

BAB 15

Status fitur pada versi final

Fitur	Status	Alasan
Daftar/detail eksperimen	Aktif	Menampilkan setting, metrik, dan artefak.
Membuat eksperimen	Dihapus	Tidak diminta dan tidak menjalankan training.
Training YOLO	Google Colab	Memerlukan Python/GPU dan proses panjang.
Production	Read-only	Melindungi data final dari pengunjung.

Bukti pengujian

- Route create/store tidak terdaftar.
- `GET /experiments/create` ditolak.
- `POST /experiments` ditolak dan tidak membuat record.
- Daftar/detail, impor lokal yang terlindungi, grafik, demo, dan AI Summary tetap diuji.
- Seluruh suite: 15 test, 83 assertions, semuanya lulus.

> **Jangan mengaktifkan operasi tulis secara publik hanya agar tombol muncul.** Jika perusahaan ingin admin online, tambahkan login, role/authorization, CSRF yang sudah ada, audit log, dan pembatasan upload; baru aktifkan `ALLOW_ADMIN_WRITES=true`.

Bagaimana menambahkan model di masa depan?

Lakukan training/evaluasi di Colab, verifikasi artefaknya, lalu sinkronkan metadata melalui proses deployment atau alat admin yang memiliki autentikasi. Form publik bukan tempat yang tepat untuk menjalankan training.

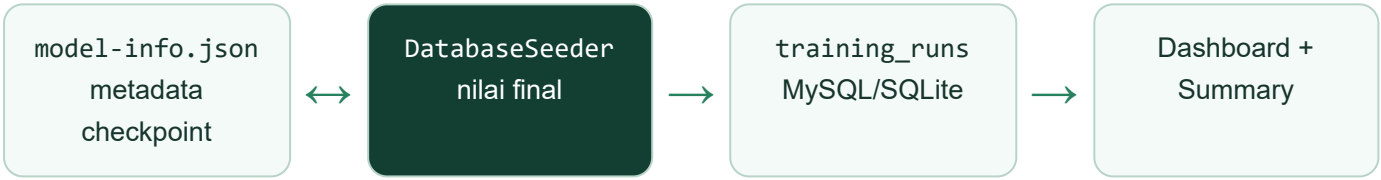
BAB 16

Database dan sumber kebenaran

Satu record `training_runs` menyimpan empat kelompok data:

Kelompok	Contoh field	Dipakai oleh
Identitas	name, model_version, dataset_name, status	Tabel dan judul.
Konfigurasi	epochs, batch_size, image_size, optimizer, device	Detail/reproduksi.
Evaluasi JSON	metrics, per_class_metrics, training_history	Kartu, bar, kurva, summary.
Artefak	results_plot_path, confusion_matrix_path, pr_curve_path	Galeri detail.
Narasi	ai_summary, summary_generated_by, notes	AI Summary dan konteks.

Rantai konsistensi model final



Test `test_final_dashboard_metrics_match_model_metadata` membandingkan precision, recall, F1, mAP50, mAP50-95, dan mAP50-95 per kelas antara metadata model dan database. Ini mencegah dashboard menampilkan angka model lama ketika checkpoint diganti.

> **Mengapa JSON untuk metrik?** Struktur metrik dapat berkembang tanpa menambah kolom untuk setiap kurva. Kekurangannya: query agregasi SQL lebih sulit daripada kolom terpisah. Untuk skala portfolio ini, fleksibilitasnya masuk akal.

BAB 17

Keamanan, batasan, dan peluang peningkatan

Kontrol yang sudah ada

- Operasi admin disembunyikan dan ditolak di production.
- POST dilindungi CSRF dan throttle.
- Input divalidasi: string length, rentang angka, MIME CSV/TXT, ukuran maksimal 5 MB.
- Summary Markdown menghapus HTML mentah dan unsafe links.
- Installer tersembunyi saat token kosong.

Batasan yang perlu disampaikan jujur

Batasan	Dampak	Perbaikan jika dilanjutkan
System aktif statis	Tidak membuktikan semua service sehat.	Tambah endpoint health aggregator.
Grafik dashboard tanpa axis/tooltip numerik	Sulit membaca epoch tertentu.	Gunakan Chart.js/Alpine atau tabel data aksesibel.
Belum ada compare view dua run	Perbandingan dilakukan dari tabel/detail.	Tambah pemilih run dan delta metric.
Artifact upload belum umum	Path final diisi seeder.	Tambah storage upload terautentikasi.
Admin online belum memiliki auth	Production harus read-only.	Tambah Laravel Breeze/Fortify dan policy.
Test set 212 gambar	Belum membuktikan seluruh kondisi lapangan.	Perlu external/field test yang lebih beragam.

> **Ini bukan kelemahan presentasi bila dijelaskan dengan benar.** Mengetahui batasan menunjukkan bahwa Anda memahami perbedaan antara prototype assessment, portfolio online, dan sistem produksi perusahaan.

BAB 18

Pertanyaan yang mungkin ditanyakan

Q: Mengapa perlu dashboard jika sudah ada hasil Colab?
Colab berorientasi pengembangan dan mudah berubah. Dashboard menyimpan hasil terpilih dalam struktur yang stabil, mudah diakses recruiter, dan menghubungkan konfigurasi, metrik, artefak, demo, serta AI Summary.

Q: Mengapa tidak ada Eksperimen Baru?
Assessment tidak memintanya dan tombol tersebut hanya membuat catatan, bukan menjalankan training. Daftar/detail tetap menyediakan seluruh bukti setting dan hasil.

Q: Mengapa aplikasi dibuat read-only?
Data final harus konsisten dan pengunjung tidak boleh mengubahnya. Training tetap berlangsung pada runtime Python/GPU yang sesuai.

Q: Mengapa mAP50-95 hanya 69,3% padahal precision 95,5%?
Precision menilai kebersihan prediksi positif, sedangkan mAP50-95 juga menguji lokalisasi pada IoU sampai 0,95 dan banyak threshold. Keduanya mengukur aspek berbeda.

Q: Mengapa test dan validation dipisah?
Validation dipakai memantau training/memilih checkpoint. Test dipakai setelah keputusan model untuk estimasi generalisasi yang lebih independen.

Q: Apakah kurva naik berarti model pasti bagus di dunia nyata?
Tidak. Itu bukti pada distribusi dataset. Masih perlu uji video lapangan, pencahayaan, sudut kamera, occlusion, dan variasi PPE nyata.

Q: Kelas mana yang perlu diperbaiki?
Masker, karena mAP50-95 63,4% dan recall 87,5% paling rendah secara relatif. Tindakan: audit anotasi, tambah contoh kecil/tertutup/cahaya rendah, lalu uji threshold.

Q: Mengapa memakai SVG buatan sendiri untuk grafik dashboard?
Ringan, tidak menambah dependency, dan cukup untuk tren tiga seri. Untuk analisis interaktif, library chart akan lebih baik.

Q: Apakah AI menentukan kelayakan model?
Tidak. AI hanya menyusun narasi. Angka dari evaluasi YOLO dan keputusan deployment tetap memerlukan kriteria manusia serta uji lapangan.

Q: Apa bukti angka dashboard tidak salah?
Seeder mengisi nilai dari metadata checkpoint dan feature test membandingkan keduanya sampai toleransi numerik sangat kecil.

BAB 19

Skenario demo dashboard 5 menit

1. **30 detik—Tujuan.** “Dashboard menyatukan evaluasi, riwayat model, demo, dan AI insight untuk tiga kelas PPE.”
2. **60 detik—Kartu.** Jelaskan precision/recall/F1, lalu bedakan mAP50 dan mAP50-95.
3. **60 detik—Kurva.** Tunjukkan validation per epoch, konvergensi, best epoch 58, dan alasan kartu berasal dari test.
4. **45 detik—Per kelas.** People terbaik, Masker terlemah; arah perbaikan dataset.
5. **60 detik—Eksperimen.** Tunjukkan konfigurasi serta hasil final; jelaskan training dilakukan di Colab dan halaman bersifat read-only.
6. **45 detik—Artefak.** Buka confusion matrix/PR/validation prediction sebagai bukti evaluasi.
7. **40 detik—AI dan keamanan.** Ollama menulis insight, angka dari DB; production read-only.

Hindari saat demo: jangan mengklaim accuracy 95,5%; jangan menyebut training berjalan di Laravel; jangan mengatakan System aktif adalah health check; jangan mengatakan semua kelas pasti muncul bersamaan; jangan membuka `.env` atau token.

BAB 20

Peta file, tautan, dan checklist belajar

Fungsi	File utama
Alamat halaman	`routes/web.php`
Memilih data dashboard	`app/Http/Controllers/DashboardController.php`
Daftar/detail dan impor lokal	`app/Http/Controllers/TrainingRunController.php`
Struktur record	`app/Models/TrainingRun.php`
Tampilan utama	`resources/views/dashboard.blade.php`
Halaman eksperimen	`resources/views/experiments/*.blade.php`
AI Summary	`SummaryController.php`, `MetricSummaryService.php`
Data final	`DatabaseSeeder.php`, `model-info.json`, CSV training
Keamanan operasi tulis	`config/deployment.php`, `ALLOW_ADMIN_WRITES`
Validasi otomatis	`tests/Feature/PpeVisionTest.php`

Checklist pemahaman

- □ Saya dapat membedakan precision dan recall.
- □ Saya dapat menjelaskan mAP50 vs mAP50-95.
- □ Saya tahu kurva dashboard berasal dari validation, kartu dari test.
- □ Saya tahu training berjalan di Colab, bukan Laravel.
- □ Saya dapat menjelaskan fungsi halaman Eksperimen read-only.
- □ Saya dapat membaca confusion matrix serta kurva PR/F1/P/R.
- □ Saya tahu mengapa Masker menjadi fokus perbaikan.
- □ Saya tahu production read-only dan alasannya.
- □ Saya tahu AI Summary bukan sumber angka.
- □ Saya dapat menyebutkan batasan dashboard secara jujur.

Tautan final

- Dashboard: ppe-vision.infinityfreeapp.com
- Eksperimen: /experiments
- AI Summary: /experiments/1/summary
- Demo Deteksi: /detection

Panduan ini dibuat dari audit source code, database seed, model metadata, artefak YOLO, screenshot aplikasi lokal, dan feature test. Tidak ada password, token, APP_KEY, atau kredensial yang disertakan.